

# Diego Alonso Veliz Ponce

## AVANCE 3-FabricioAlexisSantaCruzSaucedo-DiegoVelizPonce - FINAL.docx

-  Formación para la investigación 21-11
  -  Formación para la investigación - primer turnitin
  -  Investigación Lima
- 

### Detalles del documento

Identificador de la entrega

trn:oid:::1:3420385828

Fecha de entrega

21 nov 2025, 6:45 p.m. GMT-5

Fecha de descarga

21 nov 2025, 6:47 p.m. GMT-5

Nombre del archivo

AVANCE\_3-FabricioAlexisSantaCruzSaucedo-DiegoVelizPonce\_-\_FINAL.docx

Tamaño del archivo

98.9 KB

8 páginas

2056 palabras

10.919 caracteres

# 18% Similitud general

El total combinado de todas las coincidencias, incluidas las fuentes superpuestas, para ca...

## Fuentes principales

- 16%  Fuentes de Internet
  - 7%  Publicaciones
  - 15%  Trabajos entregados (trabajos del estudiante)
-

## Fuentes principales

- 16% Fuentes de Internet  
7% Publicaciones  
15% Trabajos entregados (trabajos del estudiante)
- 

## Fuentes principales

Las fuentes con el mayor número de coincidencias dentro de la entrega. Las fuentes superpuestas no se mostrarán.

1	Trabajos del estudiante	Universidad Tecnologica del Peru	12%
2	Trabajos del estudiante	fucn	<1%
3	Internet	medium.com	<1%
4	Internet	revistas.um.es	<1%
5	Trabajos del estudiante	UNIBA	<1%
6	Trabajos del estudiante	Universidad San Ignacio de Loyola	<1%
7	Internet	orbi.uliege.be	<1%
8	Publicación	Erik Alejandro Schulze González. "Análisis del uso de escalas de medida de influen..."	<1%
9	Internet	laccei.org	<1%
10	Internet	tesis.pucp.edu.pe	<1%
11	Internet	www.coursehero.com	<1%

12

Publicación

Allison Catalina Calle Chamorro, Geovanny Genaro Reivan Ortiz. "Tratamientos p..."

&lt;1%

“Año de la recuperación y consolidación de la economía peruana”



## Facultad de Ingeniería

### Carrera de Ingeniería de Sistemas e Informática

## TRABAJO DE INVESTIGACIÓN

### Autor

Santa Cruz Saucedo, Fabricio Alexis (**U21218670**)  
Veliz Ponce, Diego Alonso (**U19208629**)

### Docentes

Vargas Vargas. Gautama Clodomiro  
Callata Carhuapoma, Miguel Angel

Chiclayo, Perú  
Noviembre - 2025

# Efficiency of predictive maintenance with AI in fiber optic networks

1  
Fabricio Alexis Santa Cruz Saucedo, Estudiante de Ingeniería de Sistemas e Informática  
Universidad Tecnológica del Perú, [U21218670@utp.edu.pe](mailto:U21218670@utp.edu.pe)

3  
**Abstract—** Predictive maintenance is an effective way to detect problems in fiber optic networks before they occur, helping to keep service up and running and reduce operating costs. This method is based on monitoring important aspects such as attenuation, signal loss, reflections and temperature variations, also using artificial intelligence to identify faults in real time. In this article, we give you an overview of how these models work, the benefits they bring to operations and the challenges currently faced when implementing them in optical networks. Predictive maintenance is an effective way to detect problems in fiber optic networks before they occur, helping to keep service up and running and reduce operating costs. This method is based on monitoring important aspects such as attenuation, signal loss, reflections and temperature variations, also using artificial intelligence to identify faults in real time. In this article, we give you an overview of how these models work, the benefits they bring to operations and the challenges currently faced when implementing them in optical networks.

# Eficiencia del mantenimiento predictivo con IA en redes de fibra óptica

## Resumen

**El mantenimiento predictivo es una forma efectiva de detectar problemas en redes de fibra óptica antes de que ocurran, ayudando a mantener el servicio en marcha y a reducir los costos de operación. Este método se basa en monitorear aspectos importantes como la atenuación, la pérdida de señal, los reflejos y las variaciones de temperatura, usando también inteligencia artificial para identificar fallos en tiempo real. En este artículo, te damos una idea general de cómo funcionan estos modelos, los beneficios que aportan a las operaciones y los desafíos que enfrentan actualmente al implementarlos en las redes ópticas. El mantenimiento predictivo es una forma efectiva de detectar problemas en redes de fibra óptica antes de que ocurran, ayudando a mantener el servicio en marcha y a reducir los costos de operación. Este método se basa en monitorear aspectos importantes como la atenuación, la pérdida de señal, los reflejos y las variaciones de temperatura, usando también inteligencia artificial para identificar fallos en tiempo real. En este artículo, te damos una idea general de cómo funcionan estos modelos, los beneficios que aportan a las operaciones y los desafíos que enfrentan actualmente al implementarlos en las redes ópticas.**

10

4

4

8

1

(OTDR), ampliando así la posibilidad del monitoreo inteligente [17]. Por otra parte, se han desarrollado algunos marcos generales de diagnóstico y localización de fallas mediante técnicas de Deep Learning, lo cual permite no solo detectar sino también ayudar a ubicar el punto exacto del fallo en tiempo real [38]. En conjunto, estas tecnologías representan un avance significativo en la transición de un mantenimiento reactivo hacia uno predictivo, donde el análisis automático y continuo de las condiciones operativas de la red permite anticiparse a los problemas antes de que se manifiesten [1], [4], [39].

## II. METODOLOGÍA

El presente estudio se llevó a cabo mediante una revisión de artículos, para que se abarque el tema escogido, se optó por particionar el tema de investigación en sub-preguntas. Así permitiendo que se identifiquen las palabras claves que faciliten el proceso de selección y comparación de resultados. A partir de lo expuesto anteriormente se plantea la siguiente pregunta: ¿Qué modelos de IA para el mantenimiento predictivo en redes de fibra óptica son más efectivos?"

## I. INTRODUCCIÓN

Dentro del panorama de las telecomunicaciones la conectividad rápida, estable y continua se ha posicionado como una de las tecnologías más esenciales dentro de ellas. Sin embargo, su infraestructura no se libra de las vulnerabilidades como lo son; los cortes físicos, la antigüedad del cableado y las diversas condiciones climáticas adversas que puedan afectar gravemente la calidad del servicio [1][39].

Frente a esta problemática, el mantenimiento predictivo se presenta como una solución eficaz y eficiente para que se anticipen y se eviten los posibles fallos en las redes, permitiendo la reducción de sus tiempos de inactividad, evitando interrupciones inesperadas logrando optimizar los costos operativos [4],[39]. Este punto de vista ha ganado una gran relevancia gracias a las incorporaciones de algoritmos usando IA, ya que son capaces de progresar una gran cantidad de volúmenes de datos y así detectar los patrones con anomalías que preceden a las fallas técnicas [7].

Dentro del campo del Deep Learning, los modelos como lo serían las redes neuronales recurrentes tipo LSTM, estos han demostrado ser altamente precisos al momento de identificar los fallos en las redes de fibra óptica, inclusive en los escenarios con ruido de señal [5][7]. Igualmente, los modelos convolucionales (CNN) han demostrado gran eficacia en las tareas de detección de las anomalías en los diversos entornos de las telecomunicaciones [9].

Estos estudios comparativos han comprobado que la elección del algoritmo adecuado influye directamente en la efectividad del mantenimiento predictivo, también dependiendo de algunos factores como lo es la arquitectura de red, la calidad de los datos y el tipo de falla que se desea prevenir [10].

Recientes investigaciones también se exploran a los enfoques híbridos que combinan autoencoders en redes LSTM para así mejorar la detección en trazas ruidosas de reflectometría óptica

TABLA I  
KEYWORDS

Pregunta	Palabra clave
¿Qué características tienen los modelos de IA en el mantenimiento predictivo en redes de fibra óptica?	Optical Network, fiber optic, FTTH
¿Qué modelos de inteligencia artificial se utilizan para el mantenimiento predictivo en redes de fibra óptica?	Model, method, framework
¿Qué tan eficiente y eficaz son los modelos de IA para el mantenimiento predictivo de fibra óptica?	Performance, evaluation, efficiency

Fuente: Elaboración propia

El presente estudio se fundamenta en una investigación bibliográfica utilizando las bases de datos SCOPUS y WOS, haciendo uso de palabras claves para la búsqueda de los documentos, se usó esta cadena:

## TABLA II

### CADENA DE BÚSQUEDA

Scopus y Wos
( TITLE-ABS-KEY ( ( "optical network" OR "fiber optic" OR "FTTH" OR "fiber bragg" OR "fiber" ) AND ( "failure prediction" OR "fault detection" OR "anomaly detection" OR "condition monitoring" ) ) AND TITLE-ABS-KEY

1  
 $( ("model" \text{ OR } "method" \text{ OR } "approach" \text{ OR } "procedure" \text{ OR } "algorithm" \text{ OR } "framework" ) ) \text{ AND TITLE-ABS-KEY} (( "performance" \text{ OR } "efficiency" \text{ OR } "evaluation" \text{ OR } "results" \text{ OR } "optimization" \text{ OR } "comparison" ) ) \text{ AND PUBYEAR} > 2020 \text{ AND PUBYEAR} < 2026 \text{ AND ( LIMIT-TO ( DOCTYPE , "ar" ) ) AND ( LIMIT-TO ( LANGUAGE , "English" ) ) AND ( LIMIT-TO ( OA , "all" ) )}$

12 se aplicaron los filtros desde la primera búsqueda como: registros publicados entre 2021 - 2025, acceso abierto, tipo de documento (review, artículo).

2 Criterios de Inclusión y exclusión:

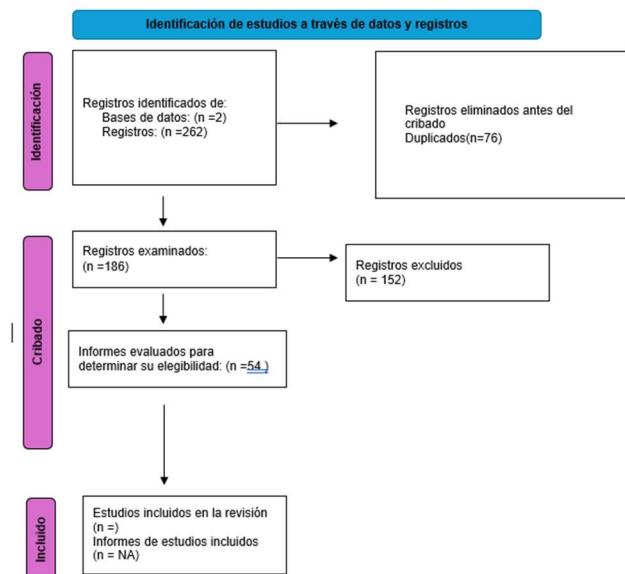
**TABLA III**

CRITERIOS DE INCLUSIÓN Y EXCLUSIÓN

Criterios de Inclusión	Criterios de Exclusión
CI1: Artículos que usen redes de fibra o fibra óptica.	CE1: Artículos que no tengan que ver con mantenimiento predictivo en redes de fibra óptica
CI2: artículos que se enfoquen en el mantenimiento predictivo en redes de fibra óptica o fibra óptica	CE2: Que se enfoquen en el monitoreo
CI3: artículos open acces y que se puedan descargar	CE3: artículos de paga y que no se puedan descargar
CI4: Estudios publicados entre los años 2021 - 2024	CE4: Publicaciones que no hablen de fibra óptica ni la red de fibra

5 Los criterios que se usaron para la inclusión y la exclusión de este documento fueron establecidos en función a los objetivos de esta investigación.

Se obtuvieron 248 artículos en ambas bases de datos ya mencionadas. Se consideró llevar una revisión sistemática siguiendo las pautas establecidas por la declaración prisma. Haciendo enfoque en la base de filtrado de la primera fase, aplicando los criterios de inclusión y exclusión. Así mismo quedando con 54 artículos para la revisión total para hacer esta investigación



ig. 1 diagrama de flujo PRISMA

### III. Resultados

Se analizaron los datos para que se demuestren para la implementación de los modelos que se han analizado para la predictividad ante fallos en redes de fibra óptica, basándonos en modelos de machine learning y de Deep learning se hace unas tablas donde se usan cuales son supervisados y cuales no, también donde que modelo es más efectivo a la hora de predecir un fallo antes de que ocurra

7

La evaluación de los modelos de aprendizaje automático para el mantenimiento predictivo en la fibra óptica se revela que tienen un prometedor alcance y diversos enfoques para que se identifique un fallo antes de que este ocurra.

La Fig. 3 muestra los modelos Deep learning más precisos, entre los cuales **LSTM(93.20%)** ha demostrado una notable capacidad, logrando una exactitud del 93.20% a partir de las métricas establecidas como la exactitud, precisión, sensibilidad, etc.

también tenemos al modelo CNN con un 92.40%, al modelo GRU con un 91.70%, al modelo autoencoder con un 90.10% y el modelo ANN con un 89.50%, este ultimo demostrando de todos los modelos ya mencionados que su capacidad para detectar y anticipar fallas futuras es de las más bajas, pero eso no quiere decir que sea una de las más malas o de las que peor identifican, porque a futuro pueden implementar cambios en su software y sistemas para que sean más precisas a la hora de detectar los fallos. Retomando al modelo más preciso que es el LSTM gracias a ello se puede deducir que este modelo es el más preciso de todos, gracias a pruebas hechas en ellas, simulaciones y la interacción de su rendimiento a la hora de hacerlos funcionar.

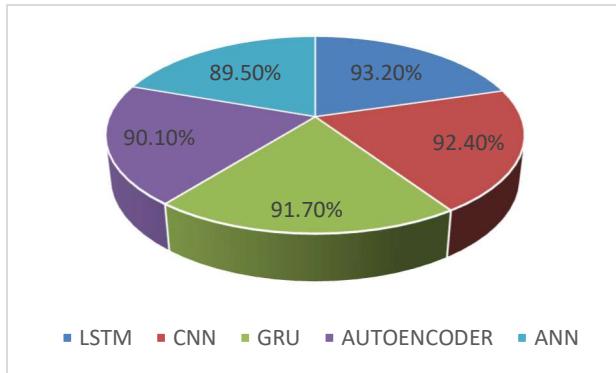


Fig. 3 Modelos Deep learning más precisos

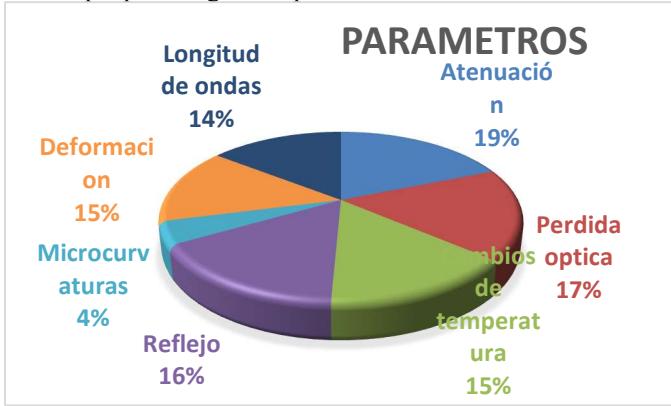
también en este aprendizaje automático es una herramienta fundamental, una de ellas es la supervisión de los modelos, ya que para ello tiene que estar una presencia humana para que pueda realmente funcionar y localizar los errores y así avisando que está realmente trabajando, en el grafico que presenta en la fig4 podemos ver que los modelos que se han mostrado el 50% es supervisado ya que esto quiere decir que pueden funcionar por si mismas pero a la vez tienden a estancarse o tardarse, por ello requiere acompañamiento o como se le diría, supervisión, el 43% no es supervisado, ya que estas pueden actuar por si mismas y por si solas ya que han demostrado que no presentan tasa de error a la hora de predecir un evento a futuro, pueden mandar datos y análisis por si solos sin necesidad de la intervención humana.



Fig.4 Tipo de aprendizaje

Los parámetros que se han usado para analizar cada uno de los modelos que se han presentado, ya que gracias a estos parámetros se pueden analizar y predecir, es como un indicador que manda señales a los sensores, ya que estos los detecta para que manden la información y así estén alerta

Con la atenuación de un 19% estos suelen estar asociados a los cortes de la fibra internas o externas, la perdida óptica con un 17% se refiere al deterioro físico del cable o defectos de los componentes, el reflejo con un 16% representan problemas en los conectores o en los empalmes, los cambios de temperaturas 15% los factores ambientales que influyen, la longitud de onda 14% esta puede provocar perdida de sincronización y las micro curvaturas son las pequeñas curvaturas que tienden a tener los cables que puedan generar perdidas localizadas



Nota: Elaborada a partir de los documentos analizados.

## V. CONCLUSIONES

El mantenimiento predictivo en redes de fibra óptica es un avance importante en cómo gestionamos las infraestructuras de telecomunicaciones hoy en día. Gracias a modelos de inteligencia artificial, tanto supervisados como no supervisados, podemos detectar fallos con bastante anticipación, lo que ayuda a reducir los tiempos de apagón y los costos que vienen con reparaciones que se hacen solo después de que algo falla. De los diferentes modelos que se han probado, los que usan redes LSTM se destacan por su gran precisión, alcanzando un 93.20% en detectar problemas antes de que lleguen a ser críticos. Les siguen muy de cerca CNN, GRU y autoencoders. Estos resultados muestran claramente que las técnicas de Deep learning tienen mucho potencial para hacer que los sistemas de fibra óptica sean más confiables. Por otro lado, analizar parámetros importantes como la atenuación, pérdida óptica, reflejos y temperatura, revela que combinar sensores con algoritmos inteligentes permite un monitoreo más detallado y eficiente del estado de la red. En resumen, los hallazgos de esta investigación confirman que el mantenimiento predictivo no solo es posible, sino que es clave para tener redes de fibra óptica más estables, resistentes y sostenibles en el futuro.



